

Clasificación Automática de Preguntas sobre OEE mediante Fine-Tuning de BERT en Español

E. Manosalvas
Maestría en Inteligencia Artificial
Universidad San Francisco de Quito
Quito, Ecuador
emanosalvasb@estud.usfq.edu.ec

Abstract—Este artículo presenta el desarrollo y evaluación de un sistema de clasificación automática de preguntas técnicas sobre el indicador de Efectividad Global del Equipo (OEE). Se empleó el modelo BERT preentrenado en español (dccuchile/bert-base-spanish-wwm-cased) como encoder contextual congelado, combinado con una cabeza de clasificación lineal entrenada mediante fine-tuning sobre un dataset balanceado de 524 preguntas en cuatro categorías: *calidad*, *velocidad*, *rendimiento* y *eficiencia OEE*. El modelo alcanzó una exactitud del 90.57 % en prueba y 92.31 % en validación, con un F1-score macro de 0.921, demostrando la viabilidad de aplicar PLMs al dominio industrial en idioma español.

Index Terms—BERT, clasificación de texto, OEE, procesamiento de lenguaje natural, PyTorch Lightning, transfer learning, manufactura.

I. INTRODUCCIÓN

La Efectividad Global del Equipo (OEE) integra tres dimensiones clave del desempeño productivo: disponibilidad, rendimiento de velocidad y calidad. Diagnosticar cada dimensión a través de preguntas técnicas especializadas es fundamental para sistemas de soporte de decisiones en manufactura.

Con la consolidación de los modelos de lenguaje preentrenados (PLMs) —en particular BERT [1]— se abrió la posibilidad de adaptar representaciones contextuales a tareas de clasificación en dominios especializados con datos reducidos. Sin embargo, la mayoría de los estudios se desarrollan en inglés. Para el español, BETO [2] representa el estado del arte, pero su aplicación al dominio industrial del OEE aún es limitada.

Este trabajo contribuye con: (1) un dataset balanceado de 524 preguntas OEE en español; (2) un clasificador BERT+cabeza lineal entrenado con PyTorch Lightning; y (3) una evaluación cuantitativa detallada por clase.

II. METODOLOGÍA

A. Dataset

El dataset consta de 524 preguntas técnicas en español distribuidas de forma balanceada en cuatro clases de etiqueta única (*single-label*), con 131 ejemplos por clase (Tabla I). El dataset fue generado sintéticamente para cubrir el espacio semántico de cada categoría. Una versión preliminar con esquema multi-label presentaba fuerte solapamiento entre etiquetas, induciendo sesgo hacia la clase *velocidad*; la transición a *single-label* balanceado corrigió este problema. La partición se realizó en

entrenamiento (80 %), validación (10 %) y prueba (10 %) con semilla fija (RANDOM_SEED=42).

TABLE I
DISTRIBUCIÓN DEL DATASET POR CLASE Y PARTICIÓN

Clase	Total	Train	Val	Test
calidad	131	105	13	13
velocidad	131	105	13	13
rendimiento	131	105	13	13
eficiencia OEE	131	103	13	15
Total	524	418	52	54

B. Arquitectura del Modelo

El modelo sigue la estrategia de *feature extraction*: el encoder BERT-base en español (~109 M parámetros) se mantiene congelado en modo *eval*, actuando exclusivamente como extractor de representaciones contextuales. Sobre el vector del token [CLS] se añade una cabeza lineal Sequential (768 → 4, Dropout 0.1) con 3072 parámetros entrenables y CrossEntropyLoss como función de pérdida. Esta decisión responde al tamaño moderado del dataset, donde el fine-tuning completo del encoder sería propenso al sobreajuste.

C. Entrenamiento

El entrenamiento fue orquestado con PyTorch Lightning. Los principales hiperparámetros se resumen en la Tabla II. Se empleó Early Stopping con paciencia de 5 épocas monitoreando *val_loss*, lo que detuvo el entrenamiento en la época 14 (checkpoint óptimo en época 13). El entrenamiento se ejecutó en GPU NVIDIA con soporte CUDA.

TABLE II
HIPERPARÁMETROS DE ENTRENAMIENTO

Hiperparámetro	Valor
Encoder	bert-base-spanish-wwm-cased
Optimizador	AdamW, $\text{lr} = 2 \times 10^{-5}$
Scheduler	Linear warmup (20 % pasos)
Batch size	32
Max tokens	512
Max épocas	50 (Early Stop: 5)
Pérdida	CrossEntropyLoss
Dropout	0.1

III. RESULTADOS Y DISCUSIÓN

A. Métricas Globales

El modelo alcanzó una exactitud de **90.57 %** en prueba y **92.31 %** en validación, convergiendo en apenas 14 épocas. Estos resultados son notables considerando que solo 3 072 parámetros fueron actualizados, lo que evidencia la potencia de las representaciones contextuales de BERT para capturar diferencias semánticas en dominio técnico especializado (Tabla III).

TABLE III
MÉTRICAS GLOBALES EN VALIDACIÓN Y PRUEBA

Métrica	Validación	Prueba
Exactitud	92.31 %	90.57 %
Pérdida (Loss)	0.4613	0.3656
F1-score macro	0.9209	—
F1-score ponderado	0.9231	—

B. Reporte por Clase

La Tabla IV muestra el reporte de clasificación en validación usando argmax. La clase *calidad* obtiene precisión perfecta (1.000) pero recall de 0.857, indicando que algunos ejemplos son asignados a otras categorías. Por el contrario, *eficiencia OEE* logra recall perfecto (1.000) con precisión 0.857, sugiriendo tendencia a clasificar ejemplos limítrofes en esta clase. La clase *rendimiento* alcanza el F1 más alto (0.9375), reflejando que sus representaciones BERT son las más discriminativas. Estos resultados son consistentes con la literatura en clasificación de dominio específico en español con BERT [2], donde se reportan F1-scores de 0.89–0.95.

TABLE IV
REPORTE DE CLASIFICACIÓN POR CLASE — VALIDACIÓN (ARGMAX)

Clase	Prec.	Rec.	F1	Sup.
calidad	1.0000	0.8571	0.9231	14
velocidad	0.9000	0.9000	0.9000	10
rendimiento	0.9375	0.9375	0.9375	16
eficiencia OEE	0.8571	1.0000	0.9231	12
macro avg	0.9237	0.9237	0.9209	52
weighted avg	0.9286	0.9231	0.9231	52

IV. CONCLUSIONES

Se demostró que un clasificador BERT con encoder congelado y cabeza lineal alcanza resultados competitivos (test acc. 90.57 %, F1 macro 0.921) para clasificar preguntas técnicas sobre OEE en español, entrenando únicamente 3 072 parámetros. La transición de multi-label a single-label balanceado fue determinante para eliminar sesgos sistemáticos en la predicción.

Entre las limitaciones destacan el uso de datos sintéticos y el tamaño moderado del dataset. Como trabajo futuro se propone: ampliar el dataset con preguntas reales de operadores; explorar fine-tuning completo con LoRA [4]; e integrar el clasificador en un sistema QA para entornos de manufactura reales.

REFERENCES

- [1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proc. NAACL-HLT*, Minneapolis, MN, USA, 2019, pp. 4171–4186.
- [2] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, and J. Pérez, “Spanish pre-trained BERT model and evaluation data,” in *PML4DC Workshop at ICLR*, 2020.
- [3] A. Vaswani *et al.*, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [4] E. Hu *et al.*, “LoRA: Low-rank adaptation of large language models,” in *Proc. ICLR*, 2022.